

基于自注意力机制的卷积循环网络语音降噪

徐浩森¹, 姜 图^{1,2}, 齐志坤¹

(1. 中国刑事警察学院公安信息技术与情报学院, 辽宁沈阳 110854;

2. 证据科学教育部重点实验室(中国政法大学), 北京 100088)

摘要: 由于对非平稳噪声进行估计是提高含噪语音降噪效果的重要影响因素, 因此利用卷积模块提高单帧含噪语音所包含的信息, 并通过 Transformer 中的自注意力机制模块, 使模型能够更加精确区分含噪语音中的噪声部分和语音部分, 从而使转置卷积模块更加高效的完成语音降噪。针对 Noisex-92 噪声库中的 15 种噪声, 分别应用 LSTM 网络、卷积循环网络和基于通道注意力机制的卷积循环网络模型进行对比分析, 同时对测试集含噪语音进行降噪处理。实验结果表明, 经过所提出的基于自注意力机制的卷积循环网络降噪后的语音在 PESQ 和 STOI 评分上均有较大提高, 语谱图显示有效减少了噪声的残留。

关键词: 语音降噪; 非平稳噪声; 自注意力机制; 深度学习

中图分类号: TP391.1 **文献标识码:** B

Convolutional Recurrent Network Speech Denoising Based on Self-Attention Mechanism

XU Hao-sen¹, JIANG Nan^{1,2}, QI Zhi-kun¹

(1. College of Public Security Information Technology and Intelligence, Criminal Investigation

Police University of China, Shenyang Liaoning 110854, China;

2. Key Laboratory of Evidence Science, Ministry of Education, China University
of Political Science and Law, Beijing 100088, China)

ABSTRACT: Since the estimation of non-stationary noise is an important factor to improve the noise reduction effect of noisy speech, we used the convolution module to improve the information contained in single frame of noisy speech, and through the self-attention mechanism module in Transformer, enabled the model to distinguish the noise part from the speech part more accurately, so that the transpose convolution module more efficiently completed the speech noise reduction. LSTM network, convolutional loop network and convolutional loop network based on channel attention mechanism were used to compare and analyze 15 kinds of noise in Noisex-92 library. Meanwhile, noise reduction was performed for the noisy speech in the test set. The experimental results show that the proposed convolutional loop network based on self-attention mechanism has a great improvement in both PESQ and STOI scores, and the spectrogram

基金项目: 证据科学教育部重点实验室(中国政法大学) 开放基金资助课题(2021KFKT09); 辽宁省科技厅联合开放基金机器人学国家重点实验室开放基金资助项目(2020-KF-12-11); 中国刑事警察学院重大计划培育项目(3242019010); 教育部重点研究项目(E-AQGABQ20202710); 辽宁省自然科学基金项目(2019-ZD-0168); 公安学科基础理论研究创新计划项目; 中央高校基本科研业务费专项资金资助(3242019010); 公安学科基础理论研究创新计划项目“公安技术基础理论与学科体系研究”(安全防范技术与工程基础理论与学科体系研究 2022XKJ0110)

收稿日期: 2022-05-23 修回日期: 2022-06-06

display effectively reduces the residual noise.

KEYWORDS: Speech noise reduction; Non-stationary noise; Self-attention mechanism; Deep learning

1 引言

语音降噪是语音识别、助听器等技术的重要预处理技术,一直以来是语音信号处理领域的重要研究内容^[1-2]。已有的降噪算法对于平稳噪声的降噪都表现出极好效果,但日常环境中的噪声多数为非平稳噪声,其特性随时间的变化而变化不易被算法所估计,且对于非平稳噪声的估计是影响语音降噪质量的重要因素^[3-4]。因此,研究非平稳噪声的含噪语音降噪具有广泛应用前景。

随着人工智能的发展,深度学习模型凭借其强大的非线性拟合能力,在多个领域中表现出优越的效果。Xu^[5]等人使用深度神经网络(DNN)通过使用含噪语音的对数功率谱训练模型生成预测的干净语音对数功率谱,在听觉质量评分上都有提升,使非平稳噪声的降噪效果明显优于基于数字信号处理的降噪算法,成为深度学习语音降噪的开山之作。Park等人^[6]在2016年提出基于卷积网络的全卷积神经网络语音降噪,使用卷积核代替全连接的神经元,可以更好的提取语音频率特征,进一步提高了语音的可懂度。Lei Sun等人^[7]考虑到语音具有时序特征,提出使用长短时记忆网络(LSTM)对语音的时序特征进行建模并降噪,实验证明,相比于DNN网络,LSTM网络可以有效提高语音的质量和可懂度。Tan K等人^[8]结合卷积网络和循环网络各自的优点,提出基于卷积循环网络(CRN)的编解码语音降噪模型,极大提高了语音的降噪效果。上述网络较以前算法虽有明显提升,但都未对模型处理中语音和噪声之间的关系进行深入研究,导致对于不同噪声的含噪语音降噪后都有不同程度上的噪声残留,严重影响模型的降噪效果。

通过注意力机制的分配,可以使模型对于噪声和语音的关注度有所区别,增加模型对于不同含噪语音降噪的效果。文献[9]在编码前引入时频注意力机制,使模型对于语音在时间和频率上具有更大的关联性,但其无法使模型对噪声和语音进行有效区分。文献[10]提出将CRN网络中的LSTM层移至编码层前和解码层后,充当注意力机制的作用,提高了降噪后语音的质量,但受限于LSTM的原理,忽略了噪声和语音在频率之间的联系。文献[11]提出使用通道注意力机制作为CRN网络的中间层,有效提高模型在低信噪比下对于不同噪声的降噪效果,但其对于每个特征块仅仅进行简短的线性相乘,不利于提高模型的泛化性。

Vaswani A等人^[12]提出Transformer模型进行序列模型的预测等,并在自然语言处理领域取得显著的效果。其借助模型中的多头自注意力机制,可以对序列数据之间的相关性进行计算,并使用Q、K、V矩阵进行权重分配,便于前馈网络进行序列预测。目前,Transformer已经在语音任务中取得明显的效果^[13]。

为提高非平稳噪声含噪语音的降噪效果,提出基于自注意力机制的卷积循环网络语音降噪模型。针对非平稳噪声的时变特性,使用局部LSTM模块以增加不同语音帧之间的时序关系。同时,为避免单个语音帧所包含信息较少从而引起自注意力机制降噪效果较差,通过卷积模块以提高单个含噪语音帧所包含的噪声和语音信息,增强自注意力机制的效果。实验结果表明,改进的模型相对于卷积循环网络语音降噪模型和基于对抗神经网络语音降噪模型等,其STOI(短时客观可理解度)和PESQ(客观语音质量评估)均有较大提升。

2 网络结构

卷积循环网络和Transformer网络在语音降噪领域发挥了显著的成效,并各自具有特色和优势。借助CRN模型的优点以及Transformer中的多头自注意力机制,使模型可以更加有效的区分噪声和语音部分,提高模型的降噪效果和噪声的泛化能力。

2.1 卷积循环网络语音降噪

卷积循环网络(CRN)使用两个独立网络产生的输出来拟合输入:一个网络作为编码器以及另一个网络作为解码器。编码器通过去除含噪语音中的噪声成分后生成输入数据的压缩形式,然后解码器对其重构从而恢复出纯净语音的估计形式,其处理流程如图1所示。




图1 卷积循环网络降噪流程

文献[8]实验表明CRN网络编码器中不同的卷积核,可以将含噪语音映射到不同的维度空间上,如高频信息,低频信息以及噪声捕捉等^[14],从而提高单个语音帧所包含的信息,解决导致单个含噪语音帧无法有效完成注意力加权^[14]。特征提取层由多个卷积模块组成,其中每个卷积模块包含卷积层、批归一化层和relu激活函数。含噪语音经过特征提取层N个叠加的卷积模块,可以获得多个不同维度上的特征信息,通过维度拼接函数将不同卷积核的结果进行拼接,使拼接后的语音每帧上都融合了不同维度上的信息,如图2所示。

卷积循环网络中的解码器由转置卷积模块和LSTM模




图2 卷积模块维度拼接

块组成。转置卷积模块由转置卷积层、批归一化层和激活函数组成,为构建模型的因果关系,转置卷积的设置与卷积模块相同。LSTM 模块由 LSTM 网络和全连接网络组成,用于恢复语音的时序关系,提高降噪后语音的听觉质量^[10]。

转置卷积是卷积的反向处理,可以重构经过编码器编码后的维度信息,从而完成语音降噪处理。如图3所示,每个特征图通过转置卷积的卷积核,根据步长依次完成映射。




图3 转置卷积映射图

2.2 基于非平稳噪声特性的位置嵌入

多头自注意力机制虽然可以高效的并行处理时序数据,但其无法对不同语音帧的位置进行识别^[15]。考虑到非平稳噪声,其噪声信息只与前后几帧相关,而与较远的语音帧无关。故本文将原有 Transformer 的位置嵌入,改为更适合语音降噪的局部 lstm (local-lstm) 模块^[15]进行位置嵌入,如图4所示。

在帧数的选择上,人类对于每个音素的发音平均时长约为 30 毫秒,一个音节发音在 120~150 毫秒之间。从而选取每 7 帧为一个语音帧段,且设置帧移为 1 帧,而后通过共享权重的局部 lstm 对每个语音帧段完成位置嵌入。

2.3 多头自注意力机制

自注意力机制作为 Transformer 的重要组成,在多个领域中展现出卓越的处理效果。注意力机制的引入可以使模型根据不同噪声情况,对含噪语音每帧上的频点进行非线性权重分配,使含噪语音中的噪声和语音具有不同的关注度,将含噪语音中的噪声与语音区分开来,进而使模型更加全面的清除噪声部分。




图4 局部 LSTM 位置编码步骤

自注意力机制结构如图5所示,输入向量通过 h 个 K 、 Q 和 V 矩阵做缩放点乘积求得两两向量之间的相似度。其中, h 为 K 、 Q 和 V 的个数,通过多个权重矩阵将输入向量映射到不同空间上。随后使用 concat 函数将 h 个输出结果进行拼接,并通过线性映射,进而转换回输入形状。




图5 自注意力机制结构

自注意力机制各数据流动如图6所示。首先, Q 、 K 和 V 矩阵由式(1)得

$$\begin{aligned} Q &= W^Q \cdot x \\ K &= W^K \cdot x \\ V &= W^V \cdot x \end{aligned} \quad (1)$$

其中, x 为编码器输出结果, W^Q 、 W^K 、 W^V 分别为权重矩阵。

使用 reshape 函数进行维度变换后,由式(2)可得,将 Q 与 K^T 做缩放点乘积,求得每个频点之间得相似度,并使用 softmax 函数进行归一化处理,形成不同含噪语音帧之间的相似概率 W_i 。

$$W_i = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \quad (2)$$

其中 d_k 为输入向量得大小,在计算点积后除以 $\sqrt{d_k}$ 可以防

止计算时梯度消失。

将求得的相似概率 W 与 V 相乘,进而求得注意力机制加权后的向量矩阵,如式(3)。

$$Attention(Q, K, V) = W_i \cdot V \quad (3)$$

求得 h 个注意力加权矩阵后,使用 *concat* 函数将其拼接并转换维度,通过线性映射,变换为与输入相同的大小,如式(4)。

$$MultiHead(Q, K, V) = Linear(concat(W_i, \dots, W_h)) \quad (4)$$

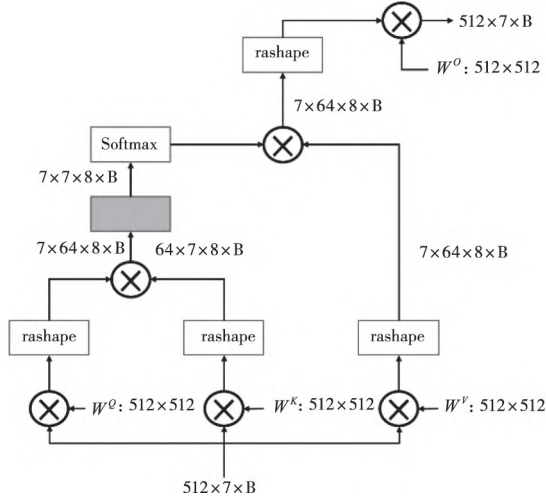


图6 自注意力机制流程图

3 基于自注意力机制的语音降噪网络

对于非平稳噪声降噪,提取不同维度下噪声的特征以及有效区分噪声和语音频点是有效提高语音降噪效果的前提。因此,本文提出的基于自注意力机制的卷积循环神经网络(Tra-CRN)可以充分结合Transformer网络和CRN网络的优势,在语音降噪中发挥最佳的降噪效果。

其具体结构如图7所示:局部LSTM作为模型的位置嵌入部分代替Transformer中的位置嵌入,将位置编码后的语音帧通过CRN网络解码器增加单帧语音所包含的信息,使用Transformer中的多头自注意力机制对含噪语音中的语音和噪声部分进行不同的权重分配,提高模型对于噪声和语音之间的关注度。将转置卷积模块作为维度还原层,对自注意力机制加权后的不同维度语音块进行上采样还原,保证语音原有的维度关系,进而提高降噪后语音的听觉质量,从而完成语音降噪。

为防止由编解码器模块增加而导致网络在训练时可能的梯度消失,在每个对应的卷积模块和转置模块添加残差链接,不仅可以避免梯度消失,同时也可以防止语音信息在深层网络流动中造成的信息丢失。

基于自注意力机制的卷积循环网络计算步骤如下

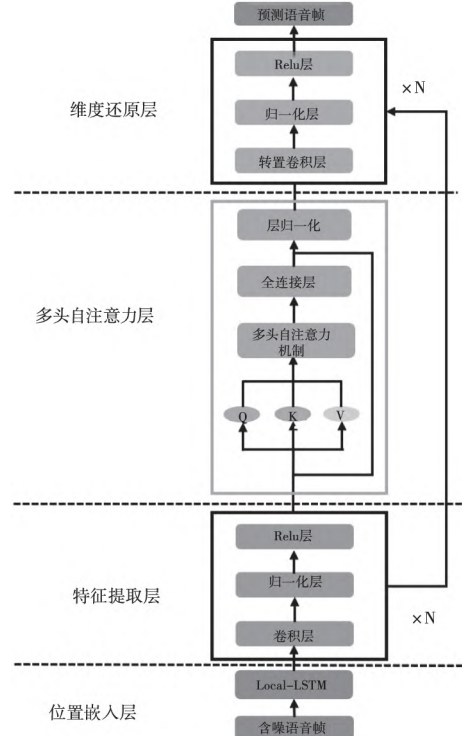


图7 Tra-CRN网络结构图

$$\begin{aligned} x &= LocalLSTM(x_{noise}); \\ x_1 &= conv(BN(relu(x))); \\ &\dots \\ x_n &= conv(BN(relu(x_i))); \\ x &= MultiHead(x_n); \\ x &= Traconv(BN(relu(x + x_1))); \\ &\dots \\ x &= Traconv(BN(relu(x + x_n))); \\ x &= fc(lstm(x)) \end{aligned} \quad (5)$$

其中 n 为卷积模块和转置卷积模块的个数。 x_{noise} 为输入的含噪语音帧 x 为降噪后的干净语音帧。

4 含噪语音库构建及训练参数设置

4.1 含噪语音库构建

实验语音选用由麻省理工学院(MIT)构建的声学-音素连续语音语料库(TIMIT库)共包含6300个句子;由美国多个主要方言地区的630个人每人说出给定的10个句子组成;所用的噪声数据为俄亥俄州立大学实验室的15类噪声(分别为:白噪声、车内噪声、军用车辆噪声、坦克内部噪声、餐厅内嘈杂噪声、高频信道噪声、粉红噪声、机枪噪声、工厂车间噪声1、工厂车间噪声2、F16座舱噪声、驱逐舰机舱噪声、驱逐舰作战室背景噪声、Buccaneer驾驶舱噪声1、Buccaneer驾驶舱噪声2)。将TIMIT数据集的语音和噪声库

中的噪声采样频率转换为 16kHz,从中选取 4500 条纯净语音(4~7s)并从 15 类噪声(每类约 3min)中随机生成与纯净语音等长的片段分别以不同程度的信噪比(-10、-5、0、5、10)进行叠加,在各个信噪比下分别生成 4500 条含噪语音的训练集(共 22500 条)。从每类噪声中随机选取叠加所需的噪声片段相比于使用相同的噪声片段可以增强模型的泛化能力,提高模型对未知噪声的降噪能力。同时,选取与训练集不同的 218 条纯净语音以相同的方法在三种信噪比(-7、0、7)下生成 654 条含噪语音构成模型的测试集。

4.2 训练参数设置

所有模型都采用 Adam 梯度优化器,损失函数为 MSE,初始学习率为 0.01,且每十轮乘以 0.1。在训练输入上,选择包含语音特征信息最多的幅度谱作为训练特征。根据人耳对相位谱不敏感特性^[6],通过预测的干净幅度谱与含噪语音相位谱逆傅里叶变换,从而将语音转换为时域波形。

5 语音降噪质量评价分析

为验证基于自注意力机制的卷积神经网络的有效性,设置三组对照模型,分别为: LSTM 网络,由三层 LSTM 网络和

一个全连接层组成,其参数分别 512、512、512 和 161;卷积循环网络(CRN),由二维卷积和转置卷积组成的编解码结构;基于通道注意力机制的卷积循环网络(A-CRN),在卷积循环网络的基础上,在中间层加入通道注意力机制。

5.1 PESQ 和 STOI 分析

实验选用感知语音质量评价(perceptual evaluation of speech quality, PESQ) 的值作为语音质量的客观评估指标^[17], PESQ 分值范围在-0.5~-4.5 间,分值越高代表降噪后的语音质量越好。在语音可懂度的评估上,使用短时客观可懂度(short time objective intelligibility, STOI) 的值作为指标^[18], STOI 分值在 0~1 范围,值越大,可懂度越高。

图 8 和图 9 为四种模型在不同噪声下 PESQ 和 STOI 得分曲线,相较于对比模型,基于自注意力机制的模型在各类噪声上都取得了较大的提高,优于其它三种模型。同时, A-CRN 模型均优于 CRN 模型,说明注意力机制的引入可以提高模型的语音质量。在一些非平稳噪声上(如: f16、m109 等类型噪声) A-CRN 和 CRN 优于 LSTM,说明卷积网络对于语音频率特征的提取优于 LSTM 网络。




图 8 各模型不同噪声降噪后 PESQ 得分




图 9 各模型不同噪声降噪后 STOI 得分

表 1 和表 2 为各模型在不同信噪比情况下的 PESQ 和 STOI 的得分情况。在不同信噪比情况下, Tra-CRN 均取得了较高的评分,且在信噪比为 7 的情况下,相较于噪声 PESQ 得分提高约 59.2%。同时,在较难处理的低信噪比情况下, Tra-CRN 依然取得了较高的得分。在 0 信噪比情况下, LSTM 模型得分高于卷积循环网络,说明在低信噪比情况下,

含噪语音时序特征的提取对语音质量的恢复效果影响更大。

表 1 各模型在不同信噪比下 PESQ 得分

	Noise	LSTM	CRN	A-CRN	Tra-CRN
-7	1.225	1.522	1.402	1.393	1.770
0	1.389	1.786	1.656	1.724	2.196
7	1.828	2.094	1.894	2.160	2.666

表 2 各模型在不同信噪比下 STOI 得分

	Noise	LSTM	CRN	A-CRN	Tra-CRN
-7	0.699	0.731	0.699	0.753	0.787
0	0.844	0.828	0.801	0.878	0.883
7	0.927	0.874	0.847	0.928	0.928

5.2 语谱图分析

图 10 为不同模型降噪后的语谱图,图 10(b) 可以看出




图 10 不同模型降噪后语谱图对比

5.3 VoiceBank-DEMAND 数据集评分对比

VoiceBank-DEMAND 数据集^[19]是语音降噪网络效果对比的主要数据集之一。由表 3 可知,Tra-CRN 网络在不同指标上的评分较当前主流的语音降噪网络均有较大的优势。表明 Tra-CRN 网络不仅对不同信噪比下的含噪语音均有较好的降噪表现,且网络对于未训练的噪声有较好的泛化性。

表 3 不同网络降噪评分对比

	Noisy	Pix2pix-J ₂ ^[20]	SEGAN ^[21]	CNN-GAN ^[20]	Tra-CRN
PESQ	2.0	2.2	2.2	2.3	2.4
STOI	91%	88%	93%	93%	93%

6 结论

非平稳噪声的估计是导致语音降噪后存在部分噪声残留的重要影响。本文提出基于多头自注意力机制的卷积循环网络语音降噪模型,通过局部 LSTM 对输入语音帧进行位置编码,并使用卷积模块增加单个语音帧所包含的维度信息,利用 Transformer 中的自注意力机制对含噪语音帧所包含的每个频点进行权重分配,将语音和噪声分开并通过转置卷积模块还原成干净语音维度,从而完成语音降噪。与不同模

含噪语音的噪声类型以非平稳噪声和窄带噪声为主。从图 10(c、d、e) 可知三种模型降噪后都有不同程度的噪声残留,其中 LSTM 模型残留的非平稳噪声最为明显;基于卷积循环网络的两种模型可以有效消除非平稳噪声,但是对于窄带噪声有较大程度的残留。图 10(f) 为 Tra-CRN 网络降噪后的语谱图,可以明显看出其基本完全消除了非平稳噪声和窄带噪声。

型在各种信噪比下的含噪语音对比发现,基于自注意力机制的卷积循环网络在各类型噪声下的降噪效果均优于其它模型,且 PESQ 和 STOI 得分均有较大提升。通过对比语谱图可知,改进的模型可以更好的去处噪声,提高语音的听觉质量。

参考文献:

- [1] 黄张翼,周翊,刘金刚,刘宏清.基于广义加权贝叶斯估计的语音增强算法研究[J].计算机仿真,2018,35(11):170-174.
- [2] 吴君钦,王迎福.一种改进窗函数的低时延语音增强算法[J].计算机仿真,2022,39(2):203-211.
- [3] 商霖.复杂环境下基于神经网络的语音增强算法研究[D].北京交通大学,2021.
- [4] 吴卫鹏.基于改进谱减的语音增强算法研究[D].南京邮电大学,2019.
- [5] Xu Y, Du J, Dai L R, et al. A regression approach to speech enhancement based on deep neural networks[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2014, 23(1): 7-19.
- [6] Park S R, Lee J. A fully convolutional neural network for speech enhancement[J]. arXiv preprint arXiv: 1609.07132, 2016.
- [7] Sun L, Du J, Dai L R, et al. Multiple-target deep learning for

- LSTM-RNN based speech enhancement [C]. 2017 Hands-free Speech Communications and Microphone Arrays (HSCMA). IEEE 2017: 136-140.
- [8] Tan K, Wang D L. A convolutional recurrent Neural network for real-time speech enhancement [C]. Interspeech. 2018, 2018: 3229-3233.
- [9] 闫昭宇, 王晶. 结合深度卷积循环网络和时频注意力机制的单通道语音增强算法 [J]. 信号处理, 2020, 36(6): 863-870.
- [10] Wang Z, Zhang T, Shao Y, et al. LSTM-convolutional-BLSTM encoder-decoder network for minimum mean-square error approach to speech enhancement [J]. Applied Acoustics, 2021, 172(2): 107647.
- [11] 徐浩森, 姜囡, 齐志坤. 基于注意力机制的卷积循环网络语音降噪 [J]. 科学技术与工程, 2022, 22(5): 1950-1957.
- [12] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [C]. Advances in Neural Information Processing Systems. 2017: 5998-6008.
- [13] JKim, MEI-Khamy and JLee. T-GSA: Transformer with gaussian-weighted self-attention for speech enhancement [C]. ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2020: 6649-6653.
- [14] Nossier S A, Wall J, Moniri M, et al. An experimental analysis of deep learning architectures for supervised speech enhancement [J]. Electronics, 2020, 10(1): 17.
- [15] 俞为伟. 基于多头注意力机制的单通道语音增强研究 [D]. 安徽大学, 2021.
- [16] Yu W, Zhou J, Wang H B, et al. SETransformer: speech enhancement transformer [J]. Cognitive Computation, 2021: 1-7.
- [17] Rix A W, Beerends J G, Hollier M P, et al. Perceptual evaluation

of speech quality (PESQ) - a new method for speech quality assessment of telephone networks and codecs [C]. Proceedings of IEEE International Conference on Acoustics, Speech, and Signal Processing. Utah: IEEE, 2001: 749-752.

- [18] Cees H. Taal, Richard C. Hendriks, Richard Heusdens, et al. An algorithm for intelligibility prediction of time-frequency weighted noisy speech [J]. IEEE Trans. Audio, Speech & Language Processing, 2011, 19(7): 2125-2136.
- [19] Valentini-Botinhao C, Wang X, Takaki S, Yamagishi J. Investigating RNN-based speech enhancement methods for noise-robust Text-to-Speech [C]. Proc. 9th ISCA Workshop on Speech Synthesis Workshop, 2016 (SSW 9): 146-152.
- [20] Shah N, Patil H A, Soni M H. Time-frequency mask-based speech enhancement using convolutional generative adversarial network [C]. 2018 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC). 2019: 1246-51.
- [21] Pascual S, Bonafonte A, J Serrà. SEGAN: speech enhancement generative adversarial network [J]. 2017: 3642-3646.

[作者简介]



徐浩森(1998-),男(汉族),四川省乐山市人,硕士研究生,主要研究领域为智能警务识别、声像资料检验。

姜囡(1979-),女(汉族),山东省武城人,教授,硕士研究生导师,主要研究领域为智能识别及公安

视听技术。

齐志坤(1998-),男(汉族),山西省朔州市人,硕士研究生,主要研究领域为智能警务识别、声像资料检验。

(上接第 381 页)

- [9] 付有斌, 康巧燕, 王建峰, 等. 标签分割的软件定义飞行自组网控制器智能部署方法 [J]. 系统工程与电子技术, 2022, 44(10): 3249-3257.
- [10] 张浩, 龙道银, 覃涛, 等. 改进人工蜂群算法的 WSN 覆盖连通优化 [J]. 计算机工程与设计, 2022, 43(10): 2701-2710.
- [11] 陈元样, 蔡泽祥, 孙宇嫣, 等. 电力物联网边缘计算终端部署与业务分配优化方法 [J]. 南方电网技术, 2022, 16(3): 100-107.
- [12] 曹望璋, 李彬, 祁兵, 等. 一种考虑业务可靠性的需求响应边缘云部署方法 [J]. 中国电机工程学报, 2021, 41(3): 846-857.
- [13] 尹浩, 魏急波, 赵海涛, 等. 一种面向复杂场景的无线通信节点智能适变架构 [J]. 中国科学: 信息科学, 2021, 51(2): 294-304.
- [14] 王莉, 魏青, 徐连明, 等. 面向通信-导航-感知一体化的应急无人机网络低能耗部署研究 [J]. 通信学报, 2022, 43(7): 1-20.

- [15] 吴晓鸽, 陈新阳, 骆晓伟, 等. 基于改进差分的多障碍视觉传感器网络部署优化 [J]. 微电子学与计算机, 2021, 38(11): 38-44.
- [16] 韦修喜, 郑宝峰. 基于混合鸡群优化算法的 WSN 节点部署优化 [J]. 河南师范大学学报(自然科学版), 2023, 51(5): 57-67.
- [17] 张利峰. 基于分数阶达尔文粒子群的不等间距节点部署优化算法 [J]. 计算机应用与软件, 2019, 36(5): 298-303+333.

[作者简介]



杨利红(1992-),女(汉族),河南开封人,硕士研究生,讲师,主要研究领域为智能检测与控制。

陈霞(1992-),女(汉族),河南郑州人,硕士研究生,讲师,主要研究领域为非线性控制。